KNN:

برای نشان دادن نتایج این قسمت از روش کسینوس که سرعتش بیشتر و اکثرا دقتش کمی بهتر از فاصله اقلیدسی شده استفاده میکنیم:

K= 1:

K = 3:

K = 5:

Naïve Bayes: با امتحان کردن مقادیر ۱، ۵، ۱۰، ۲۰، و ۵۰، بهترین مقدار alpha عددی حدود ۱۰ بود که به از ای alpha=10.4 الگوریتم برای این مجموعه داده به ما دقت ۸۹.۱ درصد میدهد.

```
Nltk:
```

1) KNN با Cosine: , K=3

(برای کمتر شدن زمان اجرا این قسمت را با نصف داده ها انجام دادم)

Nothing:

```
Confusion Matrix:

296.000 19.000 23.000 30.000

24.000 312.000 25.000 32.000

41.000 25.000 58.000 258.000

precision: [0.8043478260869565, 0.7979539641943734, 0.7142857142857143, 0.7247191011235955] mean precision: 0.76032665142266

recall: [0.7728459530026109, 0.8342245989304813, 0.7255936675461742, 0.7087912087912088] mean recall: 0.7603638570676189

f1: [0.7882822902796273, 0.8156862745098039, 0.7198952879581153, 0.7166666666666667] mean f1: 0.7601326298535533

accuracy: 0.76066666666666667

Process finished with exit code 0
```

Stopword Removal:

```
/usr/bin/python3.6 /home/esra/Desktop/MIR_Phase2/KNN.py
Confusion Matrix:
299.000 23.000 26.000 28.000
30.000 305.000 23.000 22.000
27.000 30.000 280.000 46.000
27.000 16.000 50.000 268.000
precision: [0.7952127659574468, 0.8026315789473685, 0.7310704960835509, 0.7423822714681441] mean precision: 0.7678242781141276
recall: [0.7806788511749347, 0.8155080213903744, 0.7387862796833773, 0.736263736237363] mean recall: 0.7678092221281057
f1: [0.7878787878787878, 0.8090185676392574, 0.7349081364829397, 0.7393103448275862] mean f1: 0.7677789592071428
accuracy: 0.768

Process finished with exit code 0
```

Lemmatization:

Stemming:

البته اگر به جای SnowballStemmer از LancasterStemmer استفاده کنیم که با شدت بیشتری کلمات را استم میکند، دقت یابین میآید:

مشاهده میکنیم که با بیشپردازش متن با کمک nltk دقت در حد چند دهم در صد زیاد میشود

naïve Bayes: (2

Nothing:

```
Confusion Matrix:
668.000 11.000 31.000 31.000
29.000 730.000 11.000 11.000
29.000 4.000 644.000 72.000
24.000 5.000 64.000 636.000
precision: [0.9014844804318488, 0.9346991037131882, 0.8598130841121495, 0.8724279835390947] mean precision: 0.8921061629490703
recall: [0.89066666666666667, 0.9733333333333334, 0.858666666666667, 0.848] mean recall: 0.892666666666667
fl: [0.8960429242119383, 0.953625081645983, 0.8592394929953302, 0.8600405679513186] mean fl: 0.8922370167011425
accuracy: 0.8926666666666667

Process finished with exit code 0
```

Stopword Removal:

Lemmatization:

```
Confusion Matrix:
673.000 12.000 30.000 32.000
28.000 730.000 11.000 9.000
26.000 5.000 646.000 69.000
23.000 3.000 63.000 640.000
precision: [0.9009370816599732, 0.9383033419023136, 0.8659517426273459, 0.877914951989026] mean precision: 0.8957767795446646
recall: [0.8973333333333333, 0.97333333333334, 0.86133333333333, 0.8533333333334] mean recall: 0.896333333333334
f1: [0.8991315965263862, 0.9554973821989527, 0.863636363636355, 0.8654496281271129] mean f1: 0.8959287426222038
accuracy: 0.89633333333333333
```

Stemming:

اینجا هم اگر به جای SnowballStemmer از LancasterStemmer استفاده کنیم، دقت پایین میآید:

اینجا هم مشاهده میکنیم که با پیش پر دازش متن با کمک nltk دقت در حد دهم در صد زیاد میشود.

:SVM

C = 1

```
clf = svm.SVC(kernel='linear')

print("I got here")
clf.fit(X_train, y_train)
print("I got here 2")
y_pred = clf.predict(X_test)

acc = 0
for i in range(len(y_test)):
    if y_test[i] == y_pred[i]:
        acc += 1

print(acc/ len(y_test))

I got here
I got here
I got here 2
0.81333333333333333334
```

C = 5.5

بنابر این به نظر میرسد C=5 خوبی باشد و fit کردن مدل بیش از آن فایده ی قابل توجهی نداشته باشد.

Random Forest:

به نظر میرسد وقتی Max_Depth میگذاریم دقت بدتر می شود ولی وقتی تعداد درختان را زیاد میکنیم دقت به مقدار اندکی زیاد می شود:

max_depth = None: ,N_estimators = 100

max_depth = None: ,N_estimators = 500

max_depth = 12: ,N_estimators = 500

max_depth = 64: ,N_estimators = 550

max_depth = 100: ,N_estimators = 500

max_depth = None: ,N_estimators = 750

```
/usr/bin/python3.6 /home/esra/Desktop/MIR_Phase2/random_forest.py
I got here
I got here 2
0.8133333333333334

Process finished with exit code 0
```

در کل بهتر است max_depth نگذاریم و n_estimators هم اگر ۵۰۰ باشد کافی است و بیشتر از آن افزایش دقت چندانی به ما نمی دهد.

Kmeans: (نمودار اول حاصل از خوشهبندی پیادهسازی شده و نمودار دوم حاصل از خوشهبندی Kmeans موجود در sklearn است.

