

$$L_{MSE} = \frac{1}{n} \sum_{i=1}^n (x_i - \theta)^2$$

$$\frac{dL}{d\theta} = \frac{1}{n} [-2(x_1 - \theta) - 2(x_2 - \theta) \dots - 2(x_n - \theta)]$$

$$= \frac{1}{n} [2[n\theta - \sum_{i=1}^n x_i]]$$

$$= 2\theta - 2 \times \frac{\sum_{i=1}^n x_i}{n} = 0$$

$$\rightarrow \theta = \text{میانگین } x_i \text{ ها}$$

$$L_{MAE} = \frac{1}{n} \sum_{i=1}^n \sqrt{(x_i - \theta)^2}$$

$$\frac{dL}{d\theta} = \frac{1}{n} \left[\frac{-2(x_1 - \theta)}{2\sqrt{(x_1 - \theta)^2}} + \frac{2(x_2 - \theta)}{2\sqrt{(x_2 - \theta)^2}} + \dots + \frac{-2(x_n - \theta)}{2\sqrt{(x_n - \theta)^2}} \right]$$

$$= \frac{1}{n} \left[-1 \times \sum_{i=1}^n \text{sign}(x_i - \theta) \right]$$

$$= 0 \quad \left[\text{تعداد } x_i \text{ های که از } \theta \text{ بزرگترند} - \text{تعداد } x_i \text{ های که از } \theta \text{ کوچکترند} \right]$$

$$\rightarrow \text{تعداد } x_i \text{ های که از } \theta \text{ کوچکترند} = \text{تعداد } x_i \text{ های که از } \theta \text{ بزرگترند}$$

پس θ باید میانگین باشد.


(ب) MSE از این جهت خوب است که فرمول $MSE^2 = \text{var} + \text{bias}^2$ را داریم و به این شکل قابل تقسیم است. هم چنین تابع MSE مشتق پذیر است اما تابع MAE مشتق پذیر نیست. این وقتی مهم می شود که بخواهیم از روشی مثل gradient descent برای بهینه کردن خطا استفاده کنیم. تابع MSE زمانی بهتر است که اگر میزان انحراف یک نمونه دو برابر انحراف یک نمونه دیگر باشد، منطبق باشد که penalty آن نمونه بیش از 2 برابر penalty آن نمونه دیگر باشد. به عبارتی نسبت به outlier ها بسیار حساس می شود. داریم: $MAE \leq MSE \leq n \times MAE$ یعنی هر چه تعداد نمونه ها بیشتر باشد، MSE باید با ملاحظات بیشتری مورد استفاده قرار بگیرد.

(c) روش Huber برای MSE و MAE ، ادغام می‌کنه:

$$L_{\delta}(x, \theta) = \begin{cases} \frac{1}{2}(x-\theta)^2 & |x-\theta| \leq \delta \\ \delta|x-\theta| - \frac{1}{2}\delta^2 & \text{o.w.} \end{cases}$$

این یعنی برای outlierها (که خیلی از θ دورن)، نزدیک L_{δ} ، تابع خطی از فرمول MAE است و برای سایرین، فرمول L_{δ} تابع خطی MSE است. هم چنین تابع L_{δ} جابجسته می‌باشد. این باعث می‌شود که فرامای MSE ، L_{δ} داشته باشد بدون اینکه outlierها حساس باشد. تنها مشکل این است که خود outlierها را کمتر δ باید یاد گرفته شود.

روش Log-Cosh:



$$Loss(x, \theta) = \sum_{i=1}^n \log(\cosh(\theta - x_i))$$

اگر $|x_i - \theta|$ کوچک باشد، این تابع L_{δ} تقریباً برابر $\frac{1}{2}(\theta - x)^2$ می‌شود (MSE) و اگر $|x_i - \theta|$ بزرگ باشد، این تابع هم‌انرژی $|x_i - \theta| - \log 2$ می‌شود (MAE). یعنی باز هم فرامای MSE ، ادغام می‌شود. هم چنین دوباره مستقیم‌تر است که برای مقدهایی که از روش نیوتون برای پیدا کردن θ ی کمینه شده‌ی L_{δ} استفاده می‌شود هم هستند.

سوال (2)

اگر validation ها از دیتا توزیع مختلف باشد، این مقدار احتمالاً بیش از حد روی یک توزیع overfit شده و در نتیجه توزیع دیگر را خوب پیش بینی نمی کند. (مثلاً اگر روی دیتاهایی با train باشد به خوبی پیش بینی کند اما به دیتاهایی که از آن جدا شده باشد، نتواند پیش بینی کند) راه حل این است که از روش های رایج حل overfitting مثل Cross validation استفاده از داده های بیشتر، زودتر متوقف کردن فرایند train، regularization، ensemble استفاده کنیم.

اگر validation set را یک توزیع باشد، این یعنی نتایج مدل بهتر باشد و دیتا برای تست استفاده کنیم خیلی نوسان دارد. حال یا validation set خیلی کوچک است یا اینکه مدل خیلی بزرگ است در هر دو حالت، برای اینکه مدل را خوب ارزیابی کنیم، باید داده ی validation بزرگتر را استفاده کنیم.

سوال (4)

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}}$$

$$\begin{aligned} 2 \times \text{sigmoid}(2x) - 1 &= \frac{2}{1 + e^{-2x}} - 1 = \frac{2 - 1 - e^{-2x}}{1 + e^{-2x}} \\ &= \frac{1 - e^{-2x}}{1 + e^{-2x}} \times \frac{e^x}{e^x} = \frac{e^x - e^{-x}}{e^x + e^{-x}} = \tanh(x) \end{aligned}$$

$$\rightarrow \boxed{\tanh(x) = 2 \times \text{sigmoid}(2x) - 1} \rightarrow \boxed{\text{sigmoid}(x) = \tanh\left(\frac{x}{2}\right) \times \frac{1}{2} + \frac{1}{2}}$$

پس برای اینکه بخواهیم بهای w_m^{sig} و w_0^{sig} از w_m^{tanh} و w_0^{tanh} استفاده کنیم، اول x ورودی را در $\frac{1}{2}$ ضرب می کنیم، بعد خروجی را در $\frac{1}{2}$ ضرب می کنیم و به نتیجه را با $\frac{1}{2}$ جمع می کنیم یعنی:

$$\begin{aligned} w_0^{\text{tanh}} &= w_0^{\text{sig}} + \frac{1}{2} \\ (w_1^{\text{tanh}}, w_2^{\text{tanh}}, \dots, w_m^{\text{tanh}}) &= \frac{1}{2} \times (w_1^{\text{sig}}, w_2^{\text{sig}}, \dots, w_m^{\text{sig}}) \end{aligned}$$

n ورودی را هم باید در $\frac{1}{2}$ ضرب کنیم.

$$E[L_q] = \iint |f(x) - y|^q P(x, y) dx dy$$

از آنجایی که تعداد داده‌ها محدود است (مثلاً n تا)، اگر y و x در داده‌ها باشند، $P(x, y)$ برابر $\frac{1}{n}$ است. اگر y و x در داده‌ها نباشند، $P(x, y)$ برابر صفر است. پس $E[L_q]$ را،
 این صورت هم می‌توان نوشت:

(مثلاً اگر k بار x و y را دیده باشیم، $P(x, y)$ برابر $\frac{k}{n}$ است)

$$E[L_q] = \sum_{i=1}^n |f(x_i) - y_i|^q \times \frac{1}{n} = \frac{1}{n} \sum_{i=1}^n \sqrt[q]{(f(x_i) - y_i)^{2q}}$$

$$\begin{aligned} \frac{\partial E[L_q]}{\partial f(x)} &= \frac{1}{n} \times \sum_{i=1}^n 2q \times (f(x_i) - y_i)^{2q-1} \times \frac{1}{2 \sqrt[q]{(f(x_i) - y_i)^{2q}}} \\ &= \frac{1}{n} \times q \times \sum_{i=1}^n \frac{(f(x_i) - y_i)^{2q-1}}{\sqrt[q]{(f(x_i) - y_i)^{2q}}} = \frac{q}{n} \sum_{i=1}^n \frac{(f(x_i) - y_i)^{2q-1}}{|f(x_i) - y_i|^q} \end{aligned}$$

که اگر q زوج باشد،

$$\frac{\partial E[L_q]}{\partial f(x)} = \frac{q}{n} \sum_{i=1}^n \frac{(f(x_i) - y_i)^{2q-1}}{(f(x_i) - y_i)^q} = \frac{q}{n} \sum_{i=1}^n (f(x_i) - y_i)^{q-1}$$

$$\frac{\partial [L_q]}{\partial f(x)} = 0 \rightarrow \sum_{i=1}^n (f(x_i) - y_i)^{q-1} = 0$$

وقتی $q \rightarrow 0$ ، این تابع به y_i ها وابسته می‌شود. به طور مشخص هم این نتیجه بدست می‌آید.
 چون $q \rightarrow 0$ $E[L_q] \sim \sum_{i=1}^n |f(x_i) - y_i| \times \frac{1}{n}$ می‌شود، که یعنی اگر $f(x)$ دقیقاً برابر y_i باشد،

Loss آن داده صفر می‌شود، و اگر هر عدد نامصوری باشد، این Loss تقریباً 1 می‌شود. پس

باید به گونه‌ای باشد که تعداد گسری از داده‌ها را دقیقاً برابر به ازای همان y_i ها باشد.

طبق تعریف، داده‌ای است که بیشترین زرادانی را دارد و این $f(x)$ را برای mod y_i ها بدست می‌آید.

ادله‌ی سؤال (3)
حال اگر q فرد باشد از تعدادی صغری قبل به دست می آوریم:

$$\frac{E[L_q]}{f(x)} = \frac{q}{n} \times \left[\sum_{i:1, f(x) \geq y_i}^n (f(x) - y_i)^{q-1} + \sum_{i:1, f(x) < y_i} (f(x) - y_i)^{q-1} \right]$$

که اگر $q=1$ باشد می شود:

$$\frac{q}{n} \times \sum_{i:1, f(x) \geq y_i}^n (f(x) - y_i)^0 - \sum_{i:1, f(x) < y_i} (f(x) - y_i)^0$$

$$= \frac{q}{n} \left(\begin{array}{c} \text{تعداد نمونه‌هایی که} \\ f(x) \geq y_i \end{array} - \begin{array}{c} \text{تعداد نمونه‌هایی که} \\ f(x) < y_i \end{array} \right)$$

پس اگر $\frac{E[L_q]}{f(x)}$ را صفر کنیم، $f(x)$ باید به دست آید:

$$f(x) \geq y_i \text{ تعداد نمونه‌هایی که} = f(x) < y_i \text{ تعداد نمونه‌هایی که}$$

یعنی $f(x)$ باید میانگی داده‌ها باشد.

یک نویز $\epsilon \sim N(0, \sigma^2)$ داریم. در حالت بدون نویز: $\leftarrow$ تعداد داده ها

$$E_D(\omega) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \omega) - t_n\}^2 \quad (\text{خطای sum squares})$$

حال بدون نویز، y ما این است:

(تعداد D feature است)

$$y(x, \omega) = \omega_0 + \sum_{d=1}^D \omega_d x_d$$

$$y'(x_n, \omega) = \omega_0 + \sum_{d=1}^D \omega_d (x_{nd} + \epsilon_{nd}) : \text{که با نویز شود}$$

$$= y(x_n, \omega) + \sum_{d=1}^D \omega_d \epsilon_{nd}$$

پس این خطای sum square می شود:

$$E'_D = \frac{1}{2} \sum_{n=1}^N \{y'(x_n, \omega) - t_n\}^2$$

$$= \frac{1}{2} \sum_{n=1}^N \left\{ y(x_n, \omega) + \sum_{d=1}^D \omega_d \epsilon_{nd} - t_n \right\}^2$$

$$= \frac{1}{2} \sum_{n=1}^N \left\{ (y(x_n, \omega) - t_n)^2 + 2(y(x_n, \omega) - t_n) \left(\sum_{d=1}^D \omega_d \epsilon_{nd} \right) + \left(\sum_{d=1}^D \omega_d \epsilon_{nd} \right)^2 \right\}$$

که مقدار انتظاری E'_D ، اگر بگیریم

$$E[E'_D(\omega)] = \frac{1}{2} \sum_{n=1}^N \left\{ (y(x_n, \omega) - t_n)^2 + 2(y(x_n, \omega) - t_n) \times \left(\sum_{d=1}^D \omega_d E[\epsilon_{nd}] \right) + E \left[\left(\sum_{d=1}^D \omega_d \epsilon_{nd} \right)^2 \right] \right\}$$

از آنجمله در صحت می باشد

ادرسه سوال 5
چون ϵ از توزیع نرمال $(0, \sigma^2)$ می آید، $E(\epsilon_{nd})$ صفری شود. که در نتیجه جمدی دوم اطلاعات صفری شود.
حال جمدی آخر را بازمی بینیم:

$$E \left[\left(\sum_{d=1}^D w_d \epsilon_{nd} \right)^2 \right] = E \left[\sum_{d=1}^D \sum_{d'=1}^D w_d w_{d'} \epsilon_{nd} \epsilon_{nd'} \right]$$

$$(w \text{ ها ثابت}) = \sum_{d=1}^D \sum_{d'=1}^D w_d w_{d'} E[\epsilon_{nd} \epsilon_{nd'}]$$

$$= \sum_{d=1}^D \sum_{d'=1}^D w_d w_{d'} \epsilon_{dd'}^2 \rightarrow \text{که اینجاست}$$

$$= \sum_{d=1}^D w_d^2$$

در نتیجه این، $E[E_D'(w)]$ که آخر صفری قبل بدست آمد می شود:

$$E[E_D'(w)] = \frac{1}{2} \sum_{n=1}^N \left\{ (y(x_n, w) - t_n)^2 + \sum_{d=1}^D w_d^2 \right\}$$

$$= \frac{1}{2} \sum_{n=1}^N (y(x_n, w) - t_n)^2 + \frac{N}{2} \sum_{d=1}^D w_d^2$$

Sum square error در حالت بدون خطا
L2 regularization on (L2 norm)
بردار وزن ها

تابع Loss را بازنویسی کنیم
(m تعداد ویژگی‌هاست)

$$L = \sum_{i=1}^n F_i (y_i - w_1 x_{i1} - w_2 x_{i2} - \dots - w_m x_{im})^2$$

$$= F_1 (y_1 - w_1 x_{11} - \dots - w_m x_{1m})^2 + \dots + F_n (y_n - w_1 x_{n1} - \dots - w_m x_{nm})^2$$

$$\frac{\partial L}{\partial w_j} = -x_{1j} \times 2 (y_1 - w_1 x_{11} - \dots - w_m x_{1m}) \times F_1$$

$$- x_{2j} \times 2 (y_2 - w_1 x_{21} - \dots - w_m x_{2m}) \times F_2$$

$$\vdots$$

$$- x_{nj} \times 2 (y_n - w_1 x_{n1} - \dots - w_m x_{nm}) \times F_n = 0$$

$$\rightarrow \sum_{i=1}^n F_i \times x_{ij} \times (y_i - \sum_{k=1}^m w_k x_{ik}) = 0 \quad \text{for } j=1, 2, \dots, m$$

$$\rightarrow \sum_{i=1}^n F_i \times x_{ij} \times y_i = \sum_{i=1}^n F_i \times x_{ij} \times \sum_{k=1}^m w_k x_{ik} \quad \text{for } j=1, 2, \dots, m$$

بیان ماتریسی: اگر F ماتریس $n \times n$ در نظر بگیریم $F_1, F_2, \dots, F_n$ روی قطرهای آن باشد داریم:

$$F \times X = \begin{bmatrix} F_1 & 0 & \dots & 0 \\ 0 & F_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & F_n \end{bmatrix} \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1m} \\ x_{21} & x_{22} & \dots & x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nm} \end{bmatrix} = \begin{bmatrix} F_1 x_{11} & F_1 x_{12} & \dots & F_1 x_{1m} \\ F_2 x_{21} & F_2 x_{22} & \dots & F_2 x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ F_n x_{n1} & F_n x_{n2} & \dots & F_n x_{nm} \end{bmatrix}$$

$n \times n$ $n \times m$ m

حال اگر ستون n ام ماتریس $F \times X$ را در ماتریس $y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$ ضرب کنیم می‌شود:

$$\sum_{i=1}^n F_i x_{ij} y_i$$

که این همان طرف چپ ستادی بالاست. اما ستون n ام ماتریس $F \times X$ همان سطر n ام ماتریس $(F \times X)^T$ است پس:

$$\sum_{i=1}^n F_i x_{ij} y_i = (F \times X)^T y \quad \text{سطر } n\text{ام}$$

$$= X^T F^T y \quad \text{سطر } n\text{ام}$$

F قطری است $F = F^T$

$X^T F y$ سطر n ام

حال در طرف راست تادی داریم $\sum_{k=1}^m w_k x_{ik}$

بیان ماتریسی می شود $\sum_{k=1}^m w_k x_{ik}$ X w $n \times m$ $m \times 1$ $n \times m$ w $m \times 1$

همان ماتریس می باشد. پس طرف راست می شود:

$\sum_{i=1}^n F_i x_{ij} \times (X w)$ $j = 1, 2, \dots, m$

که همان طور که طرف چپ را ساده کردیم و $\sum_{i=1}^n F_i x_{ij} y_i$ برابر با $X^T F y$ است، این طرف راست هم به طور مشابه ساده می شود.

ساده می شود: $\sum_{i=1}^n F_i x_{ij} \times (X w) = X^T F X w$ $j = 1, 2, \dots, m$

ساده می شود: $X^T F y = X^T F X w$

$\rightarrow X^T F y = X^T F X w$

$\rightarrow w = (X^T F X)^{-1} X^T F y$

بی‌شک از $x_1, x_2, \dots, x_n$ و $y_1, y_2, \dots, y_n$ استفاده می‌کنیم

$$\text{Loss} = \sum_{i=1}^n (y_i - w_j x_{ij})^2$$

$$= (y_1 - w_j x_{1j})^2 + (y_2 - w_j x_{2j})^2 + \dots + (y_n - w_j x_{nj})^2$$

$$\frac{d \text{Loss}}{d w_j} = -x_{1j} \times 2(y_1 - w_j x_{1j}) - \dots - x_{nj} \times 2(y_n - w_j x_{nj})$$

$$\frac{d \text{Loss}}{d w_j} = 0 \rightarrow x_{1j}(y_1 - w_j x_{1j}) + x_{2j}(y_2 - w_j x_{2j}) + \dots + x_{nj}(y_n - w_j x_{nj}) = 0$$

$$\rightarrow x_{1j} y_1 + x_{2j} y_2 + \dots + x_{nj} y_n = w_j (x_{1j}^2 + x_{2j}^2 + \dots + x_{nj}^2)$$

$$\rightarrow [x_{1j} \ x_{2j} \ \dots \ x_{nj}] \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = w_j \times [x_{1j} \ x_{2j} \ \dots \ x_{nj}] \begin{bmatrix} x_{1j} \\ x_{2j} \\ \vdots \\ x_{nj} \end{bmatrix}$$

$$\rightarrow x_j^T y = w_j x_j^T x_j \rightarrow w_j = \frac{x_j^T y}{x_j^T x_j}$$

سوال 7 ب) آدریس ماتریس X ستونهای مقادیر باشد، $X^T X$ ماتریس قطری می‌شود که طبعی قطری ستون نام، جمع جذبات درایه‌های ستون نام ماتریس است. دلیل:

ضرب داخلی ستون نام در

$$(X^T X)_{ij} = \sum_{k=1}^n x_{ik} x_{jk} = \sum_{k=1}^n x_{ki} x_{kj}$$

ستون نام

حال اگر ماتریس X ستونهای مقادیر باشد، ضرب داخلی ستون نام در ستون نام اگر $j \neq i$ باشد صفر می‌شود، و اگر $j = i$ باشد برابر norm_2 آن ستون می‌شود.

اداره سوال 7 ب) هم چنین معکوس یک ماتریس قطری، ماتریس قطری ای با ابعاد یکسان با آن است که درایه‌های قطری روی قطر نام آن، معکوس درایه‌های قطری سطح نام ماتریس اصلی است. (که این به سادگی با ضرب کردن این دو ماتریس و با توجه به اینکه معکوس یک ماتریس معکوس دیگری یکدست است ثابت می‌شود. توجه داریم که ماتریس $X^T X$ معکوس پذیر است چون اگر نباشد باید یکی از درایه‌های قطری آن صفر باشد و این یعنی باید norm_2 یکی از ستونهای ماتریس X صفر باشد که این با orthogonal بودن ستونها تناقض دارد)

سوی $(X X^T)^{-1}$ این شکل است:

$$\begin{bmatrix} \frac{1}{\|x_1\|^2} & 0 & \dots & 0 \\ 0 & \frac{1}{\|x_2\|^2} & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & \frac{1}{\|x_m\|^2} \end{bmatrix}$$

m تعداد ستونهای X است
 $m \times m$

حال توجه داریم که در LS معکوس، w همیشه با فزونی زیر بدست می‌آید:

$$\hat{w} = (X^T X)^{-1} X^T y$$

اثبات:

$$\text{Loss} = \sum_{i=1}^n \left(y_i - \sum_{j=1}^m w_j x_{ij} \right)^2$$

$$\frac{\partial \text{Loss}}{\partial w_k} = \sum_{i=1}^n -x_{ik} \times 2 \times \left(y_i - \sum_{j=1}^m w_j x_{ij} \right) = 0 \quad \forall k=1,2,\dots,m$$

$$\rightarrow \sum_{i=1}^n x_{ik} \left(y_i - \sum_{j=1}^m w_j x_{ij} \right) = 0$$

$$\rightarrow \sum_{i=1}^n x_{ik} y_i = \sum_{i=1}^n x_{ik} \left(\sum_{j=1}^m w_j x_{ij} \right) \quad x_i w$$

$$x^T \text{سطر } k \text{ ام} \times y = x^T \text{سطر } k \text{ ام} \times x \times w \quad \forall k=1,2,\dots,m$$

$$x^T y = x^T x w \rightarrow w = (x^T x)^{-1} x^T x y$$

حال $(x^T x)^{-1}$ را با چیزی که بدست آوردیم جایگزین می‌کنیم:

$$W_{OLS, \text{orthogonal}} = (X^T X)^{-1} X^T y = \begin{bmatrix} \frac{1}{\text{norm2}(x_{\cdot,1})} & 0 & \dots & 0 \\ 0 & \frac{1}{\text{norm2}(x_{\cdot,2})} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{1}{\text{norm2}(x_{\cdot,m})} \end{bmatrix} \begin{bmatrix} x_{11} & x_{21} & \dots & x_{n1} \\ x_{12} & x_{22} & \dots & x_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ x_{1m} & x_{2m} & \dots & x_{nm} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

$m \times m$ $m \times n$ $n \times 1$

$$\begin{bmatrix} \frac{x_{11}}{\text{norm2}(x_{\cdot,1})} & \frac{x_{21}}{\text{norm2}(x_{\cdot,1})} & \dots & \frac{x_{n1}}{\text{norm2}(x_{\cdot,1})} \\ \frac{x_{12}}{\text{norm2}(x_{\cdot,2})} & \frac{x_{22}}{\text{norm2}(x_{\cdot,2})} & \dots & \frac{x_{n2}}{\text{norm2}(x_{\cdot,2})} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{x_{1m}}{\text{norm2}(x_{\cdot,m})} & \frac{x_{2m}}{\text{norm2}(x_{\cdot,m})} & \dots & \frac{x_{nm}}{\text{norm2}(x_{\cdot,m})} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

$m \times n$ $n \times 1$

$$= \begin{bmatrix} \frac{x_{11}y_1 + x_{21}y_2 + \dots + x_{n1}y_n}{\text{norm2}(x_{\cdot,1})} \\ \frac{x_{12}y_1 + x_{22}y_2 + \dots + x_{n2}y_n}{\text{norm2}(x_{\cdot,2})} \\ \vdots \\ \frac{x_{1m}y_1 + x_{2m}y_2 + \dots + x_{nm}y_n}{\text{norm2}(x_{\cdot,m})} \end{bmatrix} = \hat{W}_{OLS, \text{orthogonal}}$$

$$w_{j, \text{orthogonal}} = \frac{1}{\text{norm2}(x_{\cdot,j})} \times \sum_{i=1}^n x_{ij} \times y_i = \frac{1}{x_j^T x_j} \times \sum_{i=1}^n x_{ji}^T y_i$$

$$= \frac{x_j^T y}{x_j^T x_j}$$

سوال 7 ج (دستور از مکان زن است که زنگها Feature ای است که استفاده می کنیم)

$$Loss = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

$$\frac{\partial Loss}{\partial \beta_0} = \sum_{i=1}^n -1 \times 2 (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\Rightarrow \sum_{i=1}^n y_i = \sum_{i=1}^n \beta_0 + \beta_1 x_i \rightarrow$$

$$n \times \frac{\sum_{i=1}^n y_i}{n} = n \times \beta_0 + \beta_1 \times n \times \frac{\sum_{i=1}^n x_i}{n}$$

$$n \times \text{میانگین } y = n \times \beta_0 + n \times \beta_1 \times \text{میانگین } x$$

$$\rightarrow \beta_0 = \underbrace{\text{میانگین } y}_{(E[y])} - \beta_1 \times \underbrace{\text{میانگین } x}_{(E[x])}$$

$$\frac{\partial Loss}{\partial \beta_1} = \sum_{i=1}^n -x_i \times 2 (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\rightarrow \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

جایگذاری β_0 از بالا

$$\rightarrow \sum_{i=1}^n x_i (y_i - E[y] + \beta_1 \times E[x] - \beta_1 x_i) = 0$$

$$\sum_{i=1}^n x_i y_i - x_i E[y] - \beta_1 (x_i^2 - x_i E[x]) = 0$$

$$\rightarrow \sum_{i=1}^n x_i (y_i - E[y]) = \beta_1 \sum_{i=1}^n x_i (x_i - E[x])$$

$$\rightarrow \beta_1 = \frac{\sum_{i=1}^n x_i (y_i - E[y])}{\sum_{i=1}^n x_i (x_i - E[x])} = \frac{\sum_{i=1}^n (x_i - E[x]) (y_i - E[y])}{\sum_{i=1}^n (x_i - E[x]) (x_i - E[x])} = \frac{\text{Cov}(x, y)^*}{\text{Var}(x)}$$

$$\frac{ab}{ac} = \frac{(a-d)b}{(a-d)c}$$

$$\Leftrightarrow abc(a-d) = abc(a-d)$$